

Fatores de risco e a sua significância no cancro

Inês Fontes Ana Sofia Mesquita Inês Ribeiro

up202207403

up202207295

up202207958

October 19, 2025

1 Introdução

Neste relatório, vamos fazer uma análise ao dataset ‘*Cancer Risk Factors*’ disponibilizado no Kaggle. Este conjunto de dados contém informações sobre diversos fatores de risco associados ao desenvolvimento de diferentes tipos de cancro.

O nosso objetivo será compreender de que forma determinados comportamentos e características individuais, como o género e a idade, podem influenciar o risco de desenvolver a doença. Pretende-se identificar possíveis padrões que permitam perceber quais os grupos mais suscetíveis a certos tipos de cancro.

Para tal, será efetuada uma análise descritiva, complementada com comparações entre grupos e visualizações gráficas, de modo a explorar o comportamento das variáveis em estudo e obter uma visão mais abrangente dos fatores de risco analisados.

2 Análise Descritiva

O dataset original contém 21 colunas. No entanto, para esta análise, selecionámos apenas 8 variáveis consideradas mais relevantes para o estudo. Foram eliminadas informações relacionadas com alimentação, atividade física, mutações genéticas e outros comportamentos de risco que, na nossa avaliação, apresentavam menor impacto no risco de desenvolvimento de cancro. Esta seleção permitiu concentrar a análise nas variáveis que poderiam fornecer resultados mais significativos e interpretáveis.

Variáveis	Descrição	Classe
Cancer_Type	Tipo de cancro associado a cada registo. Inclui cinco categorias: cancro da pele, cancro do pulmão, cancro da próstata, cancro da mama e cancro do cólon.	Original: character Utilizada: factor
Age	Idade do indivíduo (em anos).	Original: integer Utilizada: factor
Gender	Variável binária que retrata o género do indivíduo (0=feminino; 1=masculino).	Original: integer Utilizada: numeric
Family_History	Variável binária que reflete se o indivíduo possui histórico familiar de cancro (1 = presença; 0 = ausência).	Original: integer Utilizada: numeric
Air_Pollution	Nível de exposição do indivíduo à poluição atmosférica, avaliado de 0 a 10 (valores mais elevados indicam maior exposição).	Original: integer Utilizada: numeric
Occupational_Hazards	Grau de exposição do indivíduo a riscos profissionais, avaliado de 0 a 10 (valores mais elevados indicam maior exposição).	Original: integer Utilizada: numeric
BMI	Variável contínua que representa o Índice de Massa Corporal do indivíduo.	Original: numeric Utilizada: numeric
Overall_Risk_Score	Variável contínua que indica o nível de risco global estimado de desenvolver cancro, calculado com base nos fatores de risco incluídos no dataset original.	Original: numeric Utilizada: numeric

<https://www.kaggle.com/datasets/tarekmasryo/cancer-risk-factors-dataset>

Table 1: Descrição das variáveis seleccionadas do dataset *Cancer Risk Factors*.

Para garantir análises gráficas e numéricas consistentes entre as variáveis, foi necessário proceder a algumas modificações dos dados originais, como é observável na última coluna da tabela.

A variável *Age* foi alterada para factor associando idades inferiores ou iguais a 19 anos à categoria *Young*, idades acima dos 60 (inclusive) à categoria *Old* e as idades restantes à categoria *Adult*. É de notar que, após aplicadas as alterações, se verificou que não existiam dados acerca da categoria *Young*.

Para a realização da análise numérica dos dados (pág.10) foi necessário o ajuste das variáveis *Air_Pollution* e *Occupational_Hazards* que deixaram de ser níveis de 0 a 10 e passaram a ter 3 categorias (que neste caso permaneceram pertencentes à classe *numeric*). Para ambas o critério de divisão foi o seguinte: valores inferiores ou iguais a 3 associados à categoria 0, valores entre 4 e 6 inclusive associados a 1 e os restantes (superiores ou iguais a 7) associados à categoria 2.

3 Análise Gráfica

Inicialmente, realizou-se uma análise exploratória de todos os comportamentos de risco disponíveis no dataset, de modo a identificar quais teriam maior relevância para o estudo. Foram analisadas especificamente as variáveis `Smoking`, `Alcohol_Use`, `Physical_Activity_Level`, `Occupational_Hazards` e `Air_Pollution`, com o objetivo de determinar quais apresentavam maior impacto no risco de desenvolvimento dos diferentes tipos de cancro.




Figure 1: Radar chart das médias dos níveis em cada tipo de cancro dos três hábitos que não foram selecionados.

Pela Figura 1, conseguimos verificar que os níveis médios de consumo de álcool e de atividade física são reduzidos para qualquer um dos tipos de cancro analisados, embora no caso do cancro da próstata (*Prostate*) esse nível seja ligeiramente menor. O que pode estar relacionado com um menor risco de cancro influenciado por estes hábitos. Por outro lado, tal como era de esperar, o tabagismo apresenta um nível muito mais intenso no cancro do pulmão (*Lung*), refletindo a forte associação entre o hábito de fumar e esta patologia.

Com base nestas observações, consideramos mais interessante a análise da influência da poluição do ar e dos riscos profissionais, eliminando as restantes variáveis associadas a comportamentos de risco, de modo a concentrar o estudo nos fatores ambientais e ocupacionais que podem apresentar impactos distintos em cada tipo de cancro.

Vamos agora analisar 7 gráficos gerados no *RStudio*, que permitem explorar visualmente diferentes padrões e relações entre as variáveis do dataset.




Figure 2: Boxplots do Overall Risk Score distribuído pelos tipos de Cancro e em função do sexo e da idade.

Como era de esperar, as mulheres não têm dados acerca do cancro da próstata (*Prostate*) e, no cancro da mama (*Breast*), há apenas informações para um homem adulto o que corrobora as crenças sociais de que as mulheres são mais propícias a ter cancro da mama (*Breast*). De forma geral, as médias de risco são semelhantes entre grupos, embora em alguns tipos de cancro revelem diferenças subtis:

- no cancro do cólon - o risco médio em mulheres acima dos 60 anos (Old) é mais elevado quando comparado com o dos homens da mesma faixa etária e também se comparado com mulheres adultas;
- no cancro do pulmão (*Lung*) - o risco médio em homens adultos é mais elevado em comparação tanto com o mesmo género mas mais velhos como com mulheres da mesma faixa etária;
- no cancro da próstata (*Prostate*) - o risco médio em homens adultos é mais baixo do que em homens mais velhos.




Figure 3: Heat map da proporção dos hábitos (poluição do ar e riscos profissionais) em cada tipo de cancro.


Novamente se verifica que a intuição geral está de acordo com a realidade, uma vez que com este heat map conseguimos distinguir, com bastante certeza, que o tipo de cancro mais influenciado pela poluição do ar é o cancro do pulmão (*Lung*).

Para além disto, podemos observar que o cancro da pele (*Skin*) apresenta uma maior proporção de exposição tanto à poluição do ar como a riscos profissionais, indicando que estes fatores podem estar mais associados a este tipo de cancro.

O cancro da próstata (*Prostate*) apresenta proporções quase nulas em relação à poluição do ar, indicando pouca associação com este fator. O que, mais uma vez, é perceptível naturalmente visto que a próstata não constitui o sistema respiratório.

O cancro da mama (*Breast*) e o cancro do cólon, apesar de, em ambos os hábitos, apresentarem valores baixos são identificáveis diferenças nas proporções.

Distribuição média - Air Polution



Distribuição média - Occupational Hazards




Figure 4: Radar chart da média dos níveis dos hábitos (poluição do ar e riscos profissionais) por tipo de cancro.

Analisando o *Radar chart* da poluição do ar, verifica-se que o cancro do pulmão (*Lung*) tem associados níveis médios mais elevados, o que é coerente com a atualidade, dado que a inalação de partículas poluentes constitui um fator de risco. O cancro da pele (*Skin*) também evidencia níveis elevados, sugerindo que a poluição atmosférica pode contribuir indiretamente para o aumento do risco. Já o cancro da mama (*Breast*) e do cólon apresentam valores médios semelhantes, enquanto o cancro da próstata (*Prostate*) surge com os valores médios mais baixos, indicando uma menor associação com esta variável.

Por outro lado, quando analisamos os riscos profissionais, nota-se uma distribuição mais equilibrada entre os diferentes tipos de cancro, embora o cancro da pele (*Skin*) esteja associado a níveis médios significativamente superiores. Este resultado também está em consonância com a realidade atual, uma vez que a exposição a agentes químicos e a radiações em determinados ambientes de trabalho pode aumentar o risco de desenvolvimento deste tipo de cancro.




Figure 5: Dumbell plot da média do risco global em cada tipo de cancro, consoante o historial de família.

O importante a observar neste *Dumbell plot* são os comprimentos entre cada um dos pontos coloridos representativos da existência ou ausência de historial familiar, uma vez que fazendo uma análise dos mesmos ter-se-á melhor compreensão se este historial tem relevância na média do risco considerando o tipo de cancro.

É relevante salientar, então, que a maior diferença ocorre no cancro do pulmão (*Lung*) e portanto pode-se concluir que é neste grupo que o historial familiar tem mais efeito no aumento do risco (em média).

Repare-se também, que o tipo de cancro mais frequentemente associado com hereditariedade, o cancro da mama (*Breast*), apresenta uma diferença mínima entre os valores médios de risco com e sem historial familiar.




Figure 6: Tendência do risco geral em função do índice de massa corporal (BMI). Onde a linha vermelha escura representa a estimativa da tendência ajustada pelo método LOESS e a área sombreada ao redor da linha indica o intervalo de confiança de 95%, mostrando a incerteza da estimativa.

De acordo com a observação da Figura 6, o risco global aumenta de forma acentuada em indivíduos com BMI mais baixo. A partir de um determinado ponto, essa tendência estabiliza-se, mantendo o risco praticamente constante. Verifica-se assim que o aumento é mais enfático em BMI baixos, enquanto em valores mais elevados a variação é mais moderada.




Figure 7: Funnel Chart da média do risco global em cada tipo de cancro consoante a idade.

Com este *Funnel chart* pretendíamos verificar se havia alguma alteração do risco médio global em cada tipo de cancro dependendo da idade do indivíduo, uma vez que, em geral, se tende a deduzir que idades mais velhas levam a um maior risco de cancro.

Porém dificilmente essa diferença é captada através deste gráfico. Mais até se nota que no cancro da pele (*Skin*) o contrário é representado.




Figure 8: Difference plot da média do risco global em cada tipo de cancro consoante a idade.

Este gráfico foi incluído com o objetivo de ilustrar como é possível induzir o observador

a interpretações incorretas através de representações visuais enganosas, bastando neste caso, uma simples modificação na escala utilizada.

Observando este gráfico uma primeira vez, rapidamente somos levados a indicar a grande diferença do risco global no cancro da próstata (*Prostate*) satisfazendo a nossa crença intrínseca de que idade mais avançada implicará risco maior de cancro. Mas, examinando com mais pormenor, deparamo-nos com a reduzida escala onde estão representadas as diferenças e percebe-se então que talvez estas não sejam tão significativas como se esperava. Para que estas conclusões fiquem mais claras, será realizada uma análise numérica destes dados no próximo tópico.

4 Análise Numérica

Procederemos agora à análise numérica que nos possibilita avaliar a relação entre as diversas variáveis e o nível de risco, categorizado em 'Low risk' e 'High risk'. Com este objetivo, desenvolvemos testes de independência do qui-quadrado às variáveis categóricas e o teste t-Student à variável contínua (BMI), de modo a reconhecer quais os fatores têm influência estatística significativa no risco.

Variáveis		Amostra	Low (risk) < 0.43	High (risk) ≥ 0.43	Valor-p
Cancer_Type	Breast	460	231 (27.2%)	229 (19.9%)	< 2.2 * 10 ⁻¹⁶
	Colon	418	162 (19.1%)	256 (22.2%)	
	Lung	527	140 (16.5%)	387 (33.6%)	
	Prostate	305	195 (23%)	110 (9.5%)	
	Skin	290	120 (14.2%)	170 (14.8%)	
Age	Adult	679	284 (33.5%)	395 (34.3%)	0.7456
	Old	1321	564 (66.5%)	757 (65.7%)	
Family_History	Não (0)	1611	708 (83.5%)	903 (78.4%)	0.005216
	Sim (1)	389	140 (16.5%)	249 (21.6%)	
Air_Pollution ≤ 3 Baixo (0)		658	437 (51.5%)	221 (19.2%)	< 2.2 * 10 ⁻¹⁶
4 – 6 Médio (1)		573	254 (30%)	319 (27.7%)	
> 6 Alto (2)		769	157 (18.5%)	612 (53.1%)	
Occupational_Hazards					< 2.2 * 10 ⁻¹⁶
≤ 3 Baixo (0)		711	415 (49%)	296 (25.7%)	
4 – 6 Médio (1)		607	259 (30.5%)	348 (30.2%)	
> 6 Alto (2)		682	174 (20.5%)	508 (44.1%)	
BMI		26.18335 (±3.947459)	25.979 (±4.076)	26.333 (±3.845)	0.0495
Gender	Mulher (0)	1022	439 (51.8%)	583 (50.6%)	0.6397
	Homem (1)	978	409 (48.2%)	569 (49.4%)	

<https://www.kaggle.com/datasets/tarekmasryo/cancer-risk-factors-dataset>

Table 2: Descrição das variáveis selecionadas do dataset *Cancer Risk Factors*.

Para as variáveis categóricas, pretende-se testar a hipótese nula H_0 com um nível de

significância de 5%. Formulou-se então a seguinte hipótese: Não existe diferença significativa entre a variável em análise e o nível de risco.

Ao realizar o teste de independência do qui-quadrado para a variável *Cancer_Type*, obteve-se um valor-p $< 2.2 * 10^{-16}$. Dado que este valor é inferior ao nível de significância estabelecido, rejeita-se a hipótese nula. Assim, conclui-se que o tipo de cancro está significativamente associado ao risco, sendo uma variável relevante na distinção entre indivíduos de baixo e alto risco.

No que diz respeito à variável *Age*, o teste à independência do qui-quadrado apresentou um valor-p de 0.7456, superior ao nível de significância estabelecido anteriormente. Este resultado indica a ausência de diferenças estatisticamente significativas entre as diferentes faixas etárias e os dois grupos de risco.

Assim, conclui-se que a idade, por si só, não se revela um fator determinante na distinção do nível de risco. Esta conclusão está de acordo com o que se observa na representação gráfica do Funnel Chart (Figura 7) e no Difference Plot (Figura 8), onde as distribuições etárias dos dois grupos apresentam comportamentos semelhantes, sem variações significativas que indiquem uma tendência associada à idade.

Quanto ao teste à independência do qui-quadrado à variável *Family_History*, este revelou-nos um valor-p=0.005216 inferior a 0.05. Este resultado leva-nos à rejeição de H_0 . Confirmando a existência de uma relação significativa entre o historial familiar e o nível de risco. Conciliando este resultado com a interpretação gráfica (Figura 5) conclui-se que há tendência a que indivíduos com antecedentes familiares de cancro integrem o grupo de risco elevado.

No caso da variável *Air_Pollution*, o teste à independência do qui-quadrado evidenciou uma relação altamente significativa, com valor-p $< 2.2 * 10^{-16}$, que combinado com os valores da tabela acima demonstra que níveis elevados de poluição atmosférica estão fortemente associados ao grupo de risco elevado.

O teste à independência do qui-quadrado aplicado à variável *Occupational_Hazards*, indicou um valor-p inferior a $2.2 * 10^{-16}$, rejeitando-se, portanto, H_0 . Este valor-p evidenciou uma associação estatisticamente significativa entre a exposição a riscos ocupacionais e o nível de risco. Este resultado articulado com a tabela, mostra que indivíduos sujeitos a ambientes laborais mais perigosos tendem a integrar o grupo de risco elevado.

O que, novamente, comprova a conclusão apresentada na análise gráfica da Figura 4, onde se observa que os riscos profissionais exercem influência significativa no desenvolvimento de cancro da pele.

Relativamente à variável *Gender*, o teste à independência do qui-quadrado apresentou um valor-p de 0.6397, superior ao nível de significância estabelecido (0.05). Portanto, não podemos rejeitar H_0 indicando a ausência de associação estatisticamente significativa entre o género e o nível de risco global, concluindo-se que o sexo não constitui um fator determinante na distinção entre os grupos de baixo e alto risco.

No caso da variável *BMI*, para proceder ao correto preenchimento da Tabela 2, investigou-se se os seus valores não resultariam numa distribuição desvairadamente assimétrica. Através da análise da (Figura 9), constatou-se que a esta possui uma distribuição aproximadamente simétrica, o que confirma a pertinência do uso da média para melhor compreender o seu comportamento e relevância.




Figure 9: Boxplots (lado esquerdo) e histogramas (lado direito) da frequência da variável *BMI* nos três diferentes data frames (na amostra total, na subsecção com risco global baixo e na subsecção com risco global alto).

Posteriormente foi aplicado o teste t-Student, obtendo-se um valor-p de 0.0495, não muito inferior ao nível de significância de 0.05. Mesmo assim, este resultado permite rejeitar a hipótese nula (H_0), evidenciando a existência de diferenças estatisticamente significativas entre as médias de BMI dos grupos de baixo e alto risco.

Conclui-se, assim, que indivíduos com valores de BMI extremos tendem a ser a causa de variações no risco.

5 Conclusão

Com esta minuciosa análise tanto gráfica como numérica conseguimos perceber que efetivamente certas crenças intuitivas acerca desta doença tão conhecida e que tanta gente apavora não são de todo descabidas. Mas também nos apercebemos que nem sempre podemos confiar naquilo que já acreditamos ou tomamos por certo e que o melhor é sempre investigar mais a fundo.

Posto isto, reconhecemos que algumas conclusões permanecem em aberto, uma vez que um estudo mais profundo exigiria a avaliação de modelos de regressão das variáveis em questão.

Para além disto, apelamos à necessidade de se ampliar e diversificar a amostra uma vez que, apesar do dataset ter bastantes observações não continha uma grande variedade entre as mesmas. Nomeadamente, a ausência de informações relativas à categoria dos jovens (*Young*) impossibilitou um melhor estudo exploratório e comparativo.

6 Bibliografia

- <https://www.kaggle.com/datasets/tarekmasryo/cancer-risk-factors-dataset>
- <https://plotly.com/ggplot2/>
- <https://chatgpt.com/>
- Apontamentos da aula

Declaro que o presente relatório é de minha autoria e não foi utilizado previamente noutro curso ou unidade curricular, desta ou de outra instituição. As referências a outros autores (afirmações, ideias, pensamentos) respeitam escrupulosamente as regras da atribuição, e encontram-se devidamente indicadas no texto e nas referências bibliográficas, de acordo com as normas de referência. Tenho consciência de que a prática de plágio e auto-plágio constitui um ilícito académico.

Assinaturas: