

Exploração de Padrões Clínicos na Hepatite C: Uma Abordagem Baseada em Algoritmos de Aprendizagem Não Supervisionada e Supervisionada

Inês Fontes Ana Sofia Mesquita

up202207403

up202207295

1 Introdução

A Hepatite C crónica representa um desafio significativo para a saúde pública global, sendo uma das principais causas de cirrose e carcinoma hepatocelular (cancro primário do fígado). O diagnóstico preciso do estágio de fibrose hepática é crucial para determinar o prognóstico e a estratégia terapêutica. Normalmente, este diagnóstico assenta em métodos invasivos, como a biópsia hepática, que apresentam riscos para o paciente e custos elevados.

Neste contexto, a utilização de técnicas de Data Mining e Machine Learning surge como uma possível alternativa não invasiva que teria como objetivo inferir o estado do órgão sem recorrer à colheita direta de tecido hepático.

2 Análise Descritiva

O conjunto de dados utilizado neste trabalho foi o dataset *HCV-Egy-Data*, disponibilizado pelo repositório UCI Machine Learning Repository, contendo informação clínica e laboratorial de pacientes egípcios com hepatite C. Este dataset é constituído por 1385 observações e 29 variáveis. As variáveis presentes incluem informação demográfica, como idade e género, sintomas clínicos, tais como febre, náuseas e diarreia, indicadores laboratoriais, nomeadamente AST, ALT e RNA, bem como variáveis relacionadas com o estado histológico do fígado.

2.1 Tipos de variáveis

As variáveis do dataset podem ser divididas em:

- **Variáveis contínuas (*int*):** Age, BMI, WBC, RBC, HGB, Plat, AST, ALT e RNA;
- **Variáveis categóricas binárias:** Gender, Fever, Nausea.Vomting, Headache, Diarrhea, Fatigue...generalized.bone.ache, Jaundice e Epigastric.pain;
- **Variáveis categóricas:** Baseline.histological.Grading e Baselinehistological.staging (*target*).

Variável	Descrição
Age	Idade do paciente
Gender	Gênero do paciente
BMI	Índice de Massa Corporal
Fever	Presença de febre
Nausea.Vomting	Presença de náuseas e vômitos
Headache	Presença de dores de cabeça
Diarrhea	Presença de diarreia
Fatigue...generalized.bone.ache	Presença de fadiga e dores ósseas generalizadas
Jaundice	Presença de icterícia - coloração amarelada
Epigastric.pain	Presença de dor epigástrica
WBC	Contagem de glóbulos brancos
RBC	Contagem de glóbulos vermelhos
HGB	Nível de hemoglobina
Plat	Contagem de plaquetas
AST.1	Aspartato aminotransferase no instante inicial
ALT.1	Alanina aminotransferase no instante inicial
ALT.n	Alanina aminotransferase após n semanas, com $n \in \{4, 12, 24, 36, 48\}$
ALT.after.24.w	Alanina aminotransferase 24 semanas após tratamento
RNA.Base	Nível de RNA viral inicial
RNA.n	Nível de RNA viral após n semanas, com $n \in \{4, 12\}$
RNA.EOT	Nível de RNA viral no final do tratamento
RNA.EF	Nível de RNA viral no final do acompanhamento
Baseline.histological.Grading	Grau de inflamação hepática antes do tratamento
Baselinehistological.staging (<i>target</i>)	Estado histológico basal do fígado

Table 1: Descrição das variáveis presentes no dataset HCV-Egy-Data.

2.2 Transformação das variáveis categóricas

De forma a preparar os dados para a aplicação de técnicas estatísticas e algoritmos de aprendizagem, foi necessário efetuar algumas transformações nas variáveis categóricas presentes no dataset.

As variáveis binárias (*Gender*, *Fever*, *Nausea.Vomting*, *Headache*, *Diarrhea*, *Fatigue generalized bone ache*, *Jaundice* e *Epigastric.pain*) encontravam-se originalmente codificadas com os valores 1 e 2. Uma vez que estas variáveis já possuíam apenas duas categorias, não foi necessário aplicar técnicas de *One-Hot Encoding*. Assim, procedeu-se apenas à sua recodificação para valores binários 0 e 1, através da subtração de uma unidade aos valores originais.

A variável *Baseline.histological.Grading*, correspondente ao grau de inflamação hepática antes do tratamento, quantifica o nível de atividade inflamatória da hepatite num fragmento de tecido hepático. Apesar de representar uma variável ordinal, esta foi tratada como

contínua ao longo da análise, uma vez que possui vários níveis ordenados. Esta abordagem permite preservar a informação ordinal da variável e evitar o aumento desnecessário da dimensionalidade associado à aplicação de técnicas como *One-Hot Encoding*.

A variável *Baselinehistological.staging*, utilizada como variável *target* ao longo do trabalho, foi convertida para o tipo *factor* no *R* através do comando:

```
baseline.class <- factor(dataset$Baselinehistological.staging)
```

Esta transformação foi realizada porque a variável representa categorias discretas correspondentes aos diferentes estágios de fibrose hepática, não existindo interesse em tratá-la como uma variável numérica contínua. Assim, a conversão para *factor* permite que os algoritmos de classificação interpretem corretamente cada estágio como uma classe distinta.

Os diferentes estágios considerados correspondem a: 1 – fibrose portal (*Portal Fibrosis*); 2 – presença de poucos septos (*Few Septa*); 3 – presença de muitos septos (*Many Septa*); e 4 – cirrose (*Cirrhosis*).

3 Análise

3.1 Análise em Componentes Principais

A Análise de Componentes Principais foi aplicada ao conjunto de dados completo, excluindo-se apenas a variável resposta (*Baseline histological staging*), com o intuito de investigar a estrutura latente das 28 variáveis preditoras. Os resultados revelaram uma dispersão acentuada da variabilidade dos dados por um elevado número de dimensões. Ao aplicar o Critério de Kaiser, que sugere a retenção de componentes com valores próprios superiores a 1 (neste caso, onde o Desvio Padrão é > 1), observa-se, na Figura 1, que seria necessário reter as primeiras 13 componentes principais para descrever a estrutura dos dados. Mesmo com este elevado número de componentes, a variância acumulada é de apenas 54,4%, o que demonstra que a informação não está concentrada em poucos eixos, mas sim fragmentada por quase todo o conjunto de dados.

O facto de as duas primeiras componentes explicarem, em conjunto, apenas 11,2% da variabilidade total indica que uma representação bidimensional (como visualização de um biplot) é insuficiente para separar os estágios histológicos da doença. Estatisticamente, isto sugere a ausência de uma estrutura linear clara ou de correlações fortes entre os indicadores laboratoriais e o estado real do tecido hepático.

```

> summary(pca)
Importance of components:
               Comp.1      Comp.2      Comp.3
Standard deviation 1.37660997 1.11451688 1.10967152
Proportion of Variance 0.06768054 0.04436242 0.04397753
Cumulative Proportion 0.06768054 0.11204296 0.15602049
               Comp.4      Comp.5      Comp.6
Standard deviation 1.08914491 1.0778194 1.06901608
Proportion of Variance 0.04236559 0.0414891 0.04081412
Cumulative Proportion 0.19838609 0.2398752 0.28068930
               Comp.7      Comp.8      Comp.9
Standard deviation 1.05323396 1.04012266 1.02997147
Proportion of Variance 0.03961792 0.03863768 0.03788719
Cumulative Proportion 0.32030722 0.35894491 0.39683209
               Comp.10     Comp.11     Comp.12
Standard deviation 1.02709930 1.01550006 1.01215587
Proportion of Variance 0.03767618 0.03683001 0.03658784
Cumulative Proportion 0.43450827 0.47133828 0.50792612
               Comp.13     Comp.14     Comp.15
Standard deviation 1.00778145 0.99952620 0.99212559
Proportion of Variance 0.03627227 0.03568045 0.03515404
Cumulative Proportion 0.54419839 0.57987884 0.61503288
               Comp.16     Comp.17     Comp.18
Standard deviation 0.98181280 0.98051721 0.97049551
Proportion of Variance 0.03442701 0.03433621 0.03363791
Cumulative Proportion 0.64945990 0.68379611 0.71743402
               Comp.19     Comp.20     Comp.21
Standard deviation 0.95586508 0.94495399 0.93507030
Proportion of Variance 0.03263136 0.03189064 0.03122702
Cumulative Proportion 0.75006538 0.78195603 0.81318304
               Comp.22     Comp.23     Comp.24
Standard deviation 0.9283942 0.92091207 0.91322252
Proportion of Variance 0.0307827 0.03028854 0.02978483
Cumulative Proportion 0.8439657 0.87425428 0.90403912
               Comp.25     Comp.26     Comp.27
Standard deviation 0.90412373 0.87803603 0.75307894
Proportion of Variance 0.02919428 0.02753383 0.02025457
Cumulative Proportion 0.93323339 0.96076723 0.98102179
               Comp.28
Standard deviation 0.72896487

```

Figure 1: Resultado obtido na análise em componentes principais (*princomp*)

Após esta modelação efetuou-se uma análise de correlação entre as 28 variáveis predictoras como forma de corroborar algumas conclusões retiradas através do estudo anterior.




Figure 2: Heatmap das correlações das variáveis predictoras

A observação da Figura 2 revela uma predominância de correlações baixas (majoritariamente próximas de zero), com poucos grupos de variáveis a apresentarem associações significativas. Este resultado é um indicador precoce da dificuldade que os modelos de classificação virão a encontrar: a ausência de variáveis fortemente correlacionadas entre si sugere que a informação necessária para distinguir os estágios de fibrose está altamente dispersa.

Esta análise visual complementa e justifica os resultados obtidos no PCA, onde a variância não conseguiu ser concentrada em poucas componentes, reforçando a complexidade estatística do conjunto de dados clínico utilizado.

3.2 Classificação Não Supervisionada

Antes de iniciar a análise de Clusters, realizou-se uma avaliação exploratória da distribuição das variáveis preditoras e do impacto de potenciais transformações. A análise visual dos boxplots originais revelou que a aplicação de transformações logarítmicas resultaria num aumento indesejado de assimetrias e na amplificação de outliers (Figura 3). Deste modo, optou-se por manter a escala original das variáveis, procedendo-se apenas à sua normalização (*scale*) para mitigar a influência das diferentes grandezas e unidades de medida no cálculo das distâncias geométricas.




Figure 3: Boxplot das variáveis preditoras antes (a) e depois (b) da transformação logarítmica.

3.2.1 K-Médias

A definição do número ideal de clusters (k) constitui um passo crítico e desafiante na aprendizagem não supervisionada. Para fundamentar esta escolha no algoritmo K-means, foram testados diferentes critérios de validação interna: os índices de Calinski-Harabasz e de Silhouette (através da biblioteca *clusterCrit*), bem como a modelação baseada em misturas gaussianas via algoritmo Mclust.

Para a aplicação do algoritmo *K-means*, optou-se por utilizar dois grupos ($k = 2$) solução sugerida pelo critério de Calinski-Harabasz. Esta escolha fundamenta-se no facto de o método da Silhouette indicar que a ausência de partições ($k = 1$) seria o cenário ideal. Adicionalmente, a análise da Figura 4 revela que as curvas representativas dos valores de BIC (Bayesian Information Criterion) para cada modelo são praticamente horizontais e sobrepostas. Esta estabilidade demonstra que a variação no número de clusters não introduz ganhos estatísticos significativos, antecipando, desde já, a reduzida utilidade prática e a fraca separabilidade de possíveis clusters neste conjunto de dados.




Figure 4: Valores do Critério de Informação Bayesiano (BIC) para os diferentes modelos de misturas gaussianas.

Esta limitação estrutural é confirmada visualmente ao analisar a matriz de gráficos de dispersão obtida após a aplicação do algoritmo (Figura 5a). Em todos os quadrantes da matriz é possível notar uma sobreposição quase absoluta entre as observações pertencentes a ambos os clusters (representados pelas cores verde e azul), independentemente das combinações de variáveis preditoras analisadas. Não se verifica a formação de nuvens de pontos isoladas ou geometricamente compactas, exibindo-se, pelo contrário, uma distribuição homogênea e densa onde as fronteiras de decisão calculadas se fundem por completo.

Esta dispersão e conseqüente fraco desempenho refletem-se, de igual modo, quando o algoritmo de agrupamento é combinado com a Análise de Componentes Principais (PCA), conforme ilustrado na Figura 5b. A tentativa de agrupar as observações projeta resultados visualmente idênticos aos obtidos com os dados originais: a separação dos pacientes permanece nula e os pontos correspondentes a cada cluster sobrepõem-se na mesma nuvem amorfa. Este comportamento indica que a redução de dimensionalidade é incapaz de filtrar o ruído ou isolar direções de máxima variância que sejam úteis para a criação do cluster.




Figure 5: Matriz de gráficos de dispersão após aplicação de KMeans com $k = 2$ ao conjunto de dados (a) e às componentes principais (b).

A persistência desta sobreposição, mesmo após a transformação espacial dos dados, consolida de forma inequívoca as evidências anteriores dos critérios de Silhouette e BIC, comprovando que os algoritmos não supervisionados são ineficazes para isolar perfis diagnósticos distintos com base apenas em indicadores clínicos de rotina.

3.2.2 Clustering Hierárquico

Para selecionar o método de *linkage* mais adequado na análise de clustering hierárquico, utilizou-se o coeficiente de correlação cofenético. Este coeficiente mede o grau de preservação das distâncias originais entre observações pela estrutura hierárquica representada no dendrograma. Assim, quanto maior for o valor da correlação cofenética, melhor é a representação das distâncias originais pelo método de agrupamento considerado. Foram avaliados diferentes métodos de linkage, nomeadamente *complete*, *single*, *average*, *ward.D* e *ward.D2*, tendo-se comparado os respectivos coeficientes cofenéticos para identificar o método mais apropriado.

Método de Linkage	Coeficiente Cofenético
Complete	0.21
Single	0.38
Average	0.40
Ward.D	0.14
Ward.D2	0.15


Table 2: Coeficientes de correlação cofenética para diferentes métodos de linkage.

Verificou-se que o método *average linkage* apresentou o maior coeficiente de correlação

cofenética, tendo sido, por esse motivo, o método selecionado para a construção do dendrograma e posterior análise hierárquica dos dados.

A aplicação do método de *Hierarchical Clustering* sobre o conjunto de variáveis preditoras permitiu analisar a estrutura de similaridade dos dados clínicos (Figura 6). O dendrograma horizontal (6a) evidencia que as medições finais da carga viral (*RNA.12*, *RNA.EOT* e *RNA.EF*) agrupam-se a uma altura consideravelmente inferior à das restantes variáveis, traduzindo uma elevada associação biológica e uma óbvia redundância de informação temporal ao longo do acompanhamento do paciente. Por outro lado, as restantes variáveis laboratoriais e hematológicas agregam-se de forma muito mais gradual e sem quebras abruptas na altura dos nós.

Quando estes resultados são cruzados com o *heatmap* bidimensional (6b), observa-se que, quando ordenados por parecenças, apesar de algumas variáveis se estruturarem em blocos clínicos lógicos, a distribuição de cores ao nível dos doentes é fragmentada e ruidosa. Para além disto, o dendrograma vertical dos pacientes exhibe ramificações extremamente densas e sequenciais, confirmando a ausência de grupos isolados ou tipologias biológicas estanques (distintas e bem distribuídas). Esta assimetria justifica novamente o motivo pelo qual os algoritmos falham em estabelecer fronteiras de decisão nítidas e reforça a necessidade de abordagens diagnósticas mais complexas.



(a) Dendrograma do *hierarchical clustering* das variáveis clínicas

(b) Heatmap com *hierarchical clustering*

Figure 6: Visualização de resultados obtidos na aplicação de *Hierarchical Clustering*

3.3 Classificação Supervisionada

Após a análise exploratória dos dados, foram aplicados diferentes métodos supervisionados com o objetivo de prever a variável *Baseline histological staging*, correspondente ao estágio histológico basal do fígado.

Inicialmente, o conjunto de dados foi dividido em dois subconjuntos: treino e teste. Para garantir reprodutibilidade dos resultados, foi utilizada uma *seed* fixa. Aproximadamente 70%

das observações foram utilizadas para treino dos modelos e os restantes 30% para avaliação da capacidade preditiva em dados não observados anteriormente.

Posteriormente, realizou-se a normalização das variáveis explicativas através da função *scale()* do *R*. Esta transformação foi efetuada utilizando apenas os parâmetros calculados no conjunto de treino (média e desvio padrão), sendo depois aplicados ao conjunto de teste. Esta abordagem evita a utilização de informação do conjunto de teste durante o treino dos modelos (*data leakage*).

Foram então aplicados vários métodos supervisionados, nomeadamente Análise Discriminante Linear (*LDA*), Análise Discriminante Quadrática (*QDA*), classificação supervisionada baseada em modelos Gaussianos (*MclustDA*), Regressão Logística Multinomial, Árvores de Decisão, *Random Forest* e *k-Nearest Neighbors* (*kNN*).

3.3.1 Análise Discriminante Linear (LDA)

O método *Linear Discriminant Analysis* (*LDA*) foi utilizado com o objetivo de encontrar combinações lineares das variáveis explicativas capazes de maximizar a separação entre as diferentes classes da variável alvo.

Os resultados obtidos (Tabela 3) revelaram taxas de erro elevadas tanto no conjunto de treino como no conjunto de teste, indicando uma fraca capacidade discriminativa das variáveis disponíveis relativamente aos diferentes estágios histológicos.

3.3.2 Análise Discriminante Quadrática (QDA)

Foi também aplicada a técnica *Quadratic Discriminant Analysis* (*QDA*), que permite modelar fronteiras de decisão não lineares através da utilização de matrizes de covariância distintas para cada classe.

Apesar de o erro no conjunto de treino ser significativamente inferior ao observado no método LDA, o erro no conjunto de teste permaneceu elevado, sugerindo possível *overfitting* do modelo aos dados de treino (Tabela 3).

3.3.3 Classificação supervisionada com MclustDA

Aplicou-se ainda o método *MclustDA*, baseado em modelos de mistura Gaussianos. O modelo selecionado automaticamente foi o modelo XII com $G = 1$, indicando que cada classe é modelada por uma única distribuição Gaussiana com matriz de covariância diagonal e sem existência de subgrupos dentro de cada classe.

A representação da classificação obtida (Figura 7) pelo modelo evidencia uma forte sobreposição entre classes, sugerindo reduzida capacidade discriminativa das variáveis preditoras. Os resultados obtidos (Tabela 3) apresentaram novamente taxas de erro elevadas, corroborando a dificuldade na separação das diferentes classes da variável alvo.

que, apesar da relevância da variável *RNA.12* na divisão inicial dos dados, a separação obtida continua limitada, o que contribui para as elevadas taxas de erro observadas (Tabela 3).




Figure 8: Árvore de decisão obtida através do algoritmo *rpart*.

3.3.6 Random Forest

Com o objetivo de melhorar a capacidade preditiva das árvores de decisão, foi aplicado o método *Random Forest*, utilizando 500 árvores.

Apesar da maior robustez deste método relativamente a uma única árvore de decisão, os resultados (Tabela 3) continuaram a apresentar uma taxa de erro elevada no conjunto de teste. Observou-se ainda erro nulo no conjunto de treino, evidenciando forte *overfitting*, isto é, o modelo ajustou-se excessivamente aos dados de treino sem conseguir generalizar adequadamente para novos dados.

A variável identificada como mais relevante pelo modelo foi *RNA.4*, de acordo com a medida de importância das variáveis obtida através da função *importance()*.

3.3.7 *k*-Nearest Neighbors (kNN)

Foi também aplicado o método *k-Nearest Neighbors* (*kNN*), considerando inicialmente os valores $k = 1$ e $k = 3$. Verificando-se que os resultados obtidos continuavam insatisfatórios, realizou-se posteriormente um processo de otimização do parâmetro k através da função *tune.knn()*, considerando valores entre 1 e 10. O valor selecionado foi $k = 5$, correspondente ao menor erro de validação observado na Figura 9.

Apesar da otimização realizada, o método continuou a apresentar taxas de erro elevadas tanto no conjunto de treino como no conjunto de teste (Tabela 3), evidenciando dificuldades

na separação das diferentes classes da variável alvo. Os resultados obtidos sugerem que as variáveis preditoras disponíveis possuem reduzida capacidade discriminativa.




Figure 9: Erro de validação obtido para diferentes valores do parâmetro k no método kNN .

De forma a facilitar a comparação entre os diferentes métodos supervisionados considerados, apresentam-se na seguinte tabela as taxas de erro obtidas nos conjuntos de treino e de teste.

Método	Erro Treino	Erro Teste
LDA	63%	78%
QDA	32%	75%
MclustDA	65%	78%
Regressão Logística Multinomial	63%	78%
Árvore de decisão	60%	78%
Random Forest	0%	76%
kNN ($k = 1$)	0%	74%
kNN ($k = 3$)	44%	76%
kNN ($k = 5$)	48%	77%

Table 3: Comparação das taxas de erro dos métodos supervisionados.

De forma geral, todos os métodos supervisionados considerados apresentaram taxas de erro elevadas no conjunto de teste, independentemente da complexidade do modelo utilizado. Observou-se ainda que métodos mais flexíveis, como o *QDA*, o *Random Forest* e *1NN*, obtiveram erros significativamente inferiores no conjunto de treino, sem que isso se traduzisse numa melhoria relevante no desempenho em teste, sugerindo ocorrência de *overfitting*.

Adicionalmente, procurou-se representar graficamente os resultados obtidos através dos métodos *LDA*, *QDA*, *MclustDA* e *Regressão Logística Multinomial*, com o objetivo de analisar visualmente a separação entre as diferentes classes da variável alvo. Contudo, os gráficos produzidos evidenciaram uma forte sobreposição entre classes e ausência de fronteiras de decisão claramente definidas, originando representações pouco interpretáveis. Estes resultados encontram-se em concordância com as elevadas taxas de erro observadas nos diferentes modelos.

Conclui-se, assim, que as variáveis explicativas disponíveis possuem reduzida capacidade discriminativa relativamente ao estágio histológico basal do fígado, dificultando a separação entre as diferentes classes da variável alvo.

4 Conclusões Finais

O presente estudo permitiu avaliar o potencial de métodos de aprendizagem, supervisionados e não supervisionados, na previsão do grau de fibrose hepática a partir de indicadores clínicos de rotina. Os resultados obtidos demonstram que estas variáveis não possuem capacidade discriminativa suficiente para substituir métodos de diagnóstico invasivos como a biópsia.

A análise não supervisionada (através de PCA, K-means e Clustering Hierárquico) confirmou a ausência de grupos naturais nos dados, mostrando que os perfis dos doentes distribuem-se de forma contínua e sobreposta. Esta limitação estrutural refletiu-se diretamente no fraco desempenho dos modelos supervisionados, cujas taxas de erro no conjunto de teste se situaram sistematicamente entre os 74% e os 78%. O facto de algoritmos complexos, como Random Forest e kNN ($k = 1$), terem atingido 0% de erro no treino mas falhado na generalização para o teste comprova um forte efeito de overfitting, evidenciando que os modelos apenas capturaram o ruído presente nos dados. É de notar ainda que, apesar do fraco desempenho global dos modelos, as variáveis associadas à carga viral (RNA) foram as únicas a demonstrar um padrão estruturado e consistente ao longo de todo o estudo.

Para investigações futuras, a melhoria das predições poderá depender da inclusão de novas variáveis mais específicas, tais como dados de elastografia hepática ou biomarcadores moleculares, mantendo-se a biópsia, até à data, como o método insubstituível.

References

- [1] Joaquim Costa. (2026). *Material Pedagógico e Slides das Aulas da Unidade Curricular*. Faculdade de Ciências da Universidade do Porto.
- [2] Apontamentos fornecidos nas aulas.