

Parte 1:

A regressão não-paramétrica surge da necessidade de modelar relações complexas onde os modelos lineares tradicionais falham por terem uma estrutura demasiado rígida. Contrariamente à abordagem paramétrica, a regressão não-paramétrica tem como objetivo 'aprender' a função de regressão $r(x)$ sem assumir nenhuma forma específica da mesma.

Dados n pares de observações $(x_1, Y_1), \dots, (x_n, Y_n)$ a variável resposta Y está relacionada com a variável preditora x da seguinte forma:

$$Y_i = r(x_i) + \epsilon_i, \quad E(\epsilon_i) = 0, \quad i = 1, \dots, n$$

onde r é a função de regressão que queremos estimar. Este estimador é normalmente referido como suavizador e denota-se por $\hat{r}_n(x)$, diz-se que é linear se, para cada x , existir um vetor $l(x) = (l_1(x), \dots, l_n(x))^T$ tal que

$$\hat{r}_n(x) = \sum_{i=1}^n l_i(x) * Y_i$$

Daqui segue que $r = L * Y$ onde $r = (\hat{r}_n(x_1), \dots, \hat{r}_n(x_n))^T$ são os valores ajustados e L é a matriz de suavização $n \times n$ cuja i -ésima linha mostra os pesos atribuídos a cada Y_i ao formar a estimativa $\hat{r}_n(x_i)$. É também através do traço desta matriz que sabemos os Graus de Liberdade Efetivos do estimador, estes refletem a complexidade do modelo que o suavizador utiliza, por exemplo, se o suavizador segue os dados rigidamente (L_{ii} grande) o traço aumenta havendo mais graus de liberdade. **Obs:** os pesos do suavizador que irei usar têm a propriedade da sua soma ser 1, para qualquer x , implicando a preservação de curvas constantes.

Em inferência estatística, o **Risco** (R) (ou erro quadrático médio) é uma das métricas chave para avaliar a performance pontual de um estimador, representando a 'distância' entre a função real desconhecida $r(x)$ e a função estimada pelo modelo $\hat{r}(x)$ da seguinte forma:

$$R(h) = E \left[\frac{1}{n} \sum_{i=1}^n (\hat{r}_n(x_i) - r(x_i))^2 \right]$$

Queremos, então, escolher h -**bandwidth** - que minimize o risco, mas como o seu valor real seria inalcançável, uma vez que depende da função desconhecida $r(x)$, usa-se uma estimativa quase não enviesada do risco (demonstrada em [1]) - o *leave-one-out cross validation score*. Defini-se então:

$$\hat{R}(h) = cv = \frac{1}{h} \sum_{i=1}^n (Y_i - \hat{r}_{(-i)}(x_i))^2$$

onde $\hat{r}_{(-i)}$ é o estimador obtido omitindo o i -ésimo par (x_i, Y_i) .

Dentro da classe dos suavizadores baseados em núcleos (*kernel*), o estimador **Nadaraya-Watson** destaca-se como uma técnica fundamental para a modelação de tendências não lineares. Em vez de assumir uma forma global para os dados, este método estima a função de regressão através do cálculo de médias locais móveis:

$$\hat{r}_n(x) = \sum_{i=1}^n w_i * Y_i$$

onde os pesos $w_i(x)$ são dados por $w_i(x) = \frac{K\left(\frac{x-x_i}{h}\right)}{\sum_{j=1}^n K\left(\frac{x-x_j}{h}\right)}$, K é um núcleo e h é o parâmetro de suavização.

Parte 2:

Neste relatório irei analisar o dataset *mcycle* proveniente da biblioteca *MASS* disponível no *R* que fornece um conjunto de 133 medições da aceleração da cabeça (*accel*) em função do tempo (*times*) num acidente de mota simulado para testar capacetes.

A metodologia que adotei consistiu na divisão inicial da amostra em conjuntos de treino (80%) e teste (20%). No conjunto de treino, apliquei a validação cruzada leave-one-out (LOOCV) para a seleção da *bandwidth* (h) ótima, minimizando o risco estimado. Embora este possa não ser o método mais eficiente do ponto de vista computacional, no contexto dos meus dados revelou-se adequado e mais intuitivo de implementar. Por fim, comparei a performance do modelo não-paramétrico com a da regressão linear simples através do erro quadrático médio (MSE) e do coeficiente de determinação (R^2) calculados no conjunto de teste, garantindo uma avaliação imparcial da capacidade de generalização de ambos os modelos.

Este dataset foi escolhido precisamente porque a relação entre a variável resposta e a variável preditora é claramente não linear, facto que pode ser observado na dispersão dos pontos representados a cinzentos na Figura 1 onde são também de notar as grandes diferenças entre o ajuste da reta de regressão linear simples e o ajuste resultante da utilização do estimador *kernel* Nadaraya-Watson. Enquanto a primeira impõe uma estrutura funcional rígida que não consegue capturar adequadamente o comportamento dos dados, o estimador não-paramétrico adapta-se de forma mais flexível à estrutura subjacente, proporcionando um ajustamento substancialmente superior. Superioridade esta que é corroborada pelos resultados numéricos apresentados na Tabela 1 onde o erro quadrático médio (MSE) associado ao estimador Nadaraya-Watson é inferior ao obtido pela regressão linear, indicando um melhor desempenho preditivo tal como, de forma consistente, o coeficiente de determinação (R^2) apresenta um valor mais elevado no modelo não-paramétrico revelando que este explica uma maior proporção da variável resposta.

A figura 2 tem o intuito de explicitar a importância da escolha da *bandwidth* (h) no ajuste do estimador *kernel* Nadaraya-Watson. Nos dois primeiros gráficos, da esquerda para a direita, foram atribuídos valores de *bandwidth* de 10 e 20, respetivamente, observando-se um elevado grau de suavização, que conduz a uma perda de detalhes, uma vez que, um maior valor de h leva o núcleo a dar peso a muitos pontos, inclusive aos mais distantes do ponto de interesse (aumento do viés). No terceiro gráfico, onde $h = 1$, o estimador apresenta um ajuste mais flexível, acompanhando de forma muito próxima a estrutura dos dados, produzindo uma estimativa muito irregular (aumento da variância).

Concluindo, os resultados obtidos mostram que, para relações claramente não lineares, a regressão não-paramétrica, em particular o uso do estimador *kernel* Nadaraya-Watson, apresenta um desempenho superior ao da regressão linear, tanto do ponto de vista gráfico como em termos das métricas de avaliação. Este estudo evidencia ainda a importância da escolha adequada do parâmetro de suavização, sendo a validação cruzada fundamental para garantir um equilíbrio apropriado entre viés e variância. É de salientar que a escolha do núcleo tem um efeito reduzido na estimativa ([1]), o que me levou a utilizar sempre o mesmo - Gaussiano.

Acrescento ainda que como perspetiva de trabalho futuro, seria interessante a extensão desta análise a conjuntos de dados de maior dimensão e a utilização de outros métodos não-paramétricos, como splines ou regressão local, de modo a aprofundar a avaliação e comparação dos seus desempenhos preditivos.

Parte 3:

1. **Wasserman, L. (2006).** *All of Nonparametric Statistics*. Springer Texts in Statistics.
2. **Wasserman, L. (2004).** *All of Statistics: A Concise Course in Statistical Inference*. Springer Texts in Statistics.

Anexos

	MSE	R^2
Regressão Linear Simples	1511.7	0.061
Regressão Não-Paramétrica (NW)	503.3	0.688

Table 1: Erro quadrático médio e coeficiente de determinação para o modelo linear simples e para o modelo não-paramétrico.




Figure 1: Dispersão dos dados com sobreposição das retas de regressão linear simples (a azul) e de regressão não-paramétrica (a vermelho).




Figure 2: Impacto da bandwidth h no ajuste do estimador Nadaraya Watson. No primeiro e segundo gráfico do lado esquerdo fixou-se $h = 10$ e $h = 20$ e no último $h = 1$ estando em todos presente o valor ótimo $h = 3$.